VIETNAM NATIONAL UNIVERSITY, HO CHI MINH CITY
UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING

# DATA MINING (CO3029)

## Assignment

# "*HOUSE PRICE PREDICTION USING LINEAR REGRESSION AND RANDOM FOREST*"

**Instructor(s)**: Đỗ Thanh Thái

**Students**: *Nguyễn Xuân Huy Hoàng - L02 - N12 - 2311070* (Leader)
*Phan Đăng Nhật Huy - L02 - N12 - 2311226*
*Sẻ Thế Hưng - L02 - N12 - 2053079*

HO CHI MINH CITY, FEBRUARY 2026

# Contents

**Member list & Workload** **4**

**List of Figures** **4**

**List of Tables** **4**

**1 Giới thiệu tổng quan** **5**
1.1 Đặt vấn đề và Lý do chọn đề tài . . . 5
1.2 Mô tả tập dữ liệu . . . 5
1.3 Mục tiêu cụ thể . . . 5

**2 Tiền xử lý dữ liệu** **6**
2.1 Làm sạch dữ liệu . . . 6
2.1.1 Xử lý theo nhóm đặc tính . . . 6
2.1.2 Xử lý theo logic phụ thuộc và thống kê khu vực . . . 6
2.2 Chuyển đổi dữ liệu . . . 7
2.2.1 Mã hóa thứ tự (Ordinal Encoding) . . . 7
2.2.2 Mã hóa biến giả (One-Hot Encoding) . . . 7
2.3 Chuẩn hóa dữ liệu . . . 8
2.4 Trích xuất đặc trưng . . . 8
2.4.1 Loại bỏ các thuộc tính ít giá trị . . . 8
2.4.2 Tạo lập các biến tổng hợp . . . 8
2.4.3 Đặc trưng về thời gian và trạng thái . . . 8
2.4.4 Biến tương tác . . . 9
2.4.5 Giảm lệch . . . 9

**3 Mô hình hoá cơ sở - kỹ thuật trong đề cương** **10**
3.1 Lựa chọn thuật toán . . . 10
3.1.1 Cơ sở lựa chọn: . . . 10
3.1.2 Ý nghĩa của việc chọn mô hình cơ sở: . . . 11
3.2 Huấn luyện và Đánh giá . . . 11
3.2.1 Quá trình huấn luyện: . . . 11
3.2.2 Trực quan hóa kết quả mô hình: . . . 12
3.2.3 Kết quả đánh giá: . . . 13
3.2.4 Diễn giải kết quả: . . . 13
3.3 Nhận xét giới hạn của mô hình cơ sở . . . 14
3.3.1 Những giới hạn chính: . . . 14
3.3.2 Chiến lược cải thiện: . . . 14

**4 Mô hình hóa nâng cao** **15**
4.1 Lựa chọn kỹ thuật . . . 15
4.1.1 Cơ sở lựa chọn: . . . 15
4.1.2 Ý nghĩa học thuật: . . . 15
4.2 Quá trình huấn luyện . . . 15
4.2.1 Thiết lập tham số: . . . 15
4.2.2 Quá trình huấn luyện: . . . 16
4.2.3 Phân tích độ quan trọng đặc trưng: . . . 17
4.3 Kết quả đánh giá mô hình nâng cao . . . 18
4.3.1 Kết quả đánh giá: . . . 18
4.3.2 Nhận xét: . . . 19

**5 So sánh, trực quan hóa và khai phá tri thức** **20**
5.1 Trực quan hóa và So sánh hiệu năng . . . 20
5.2 Khai phá tri thức . . . 20

**6 Ra quyết định và kết luận** **22**
6.1 Tư vấn chiến lược kinh doanh . . . . . 22
6.2 Kết luận . . . . . 22
6.3 Hướng phát triển tương lai . . . . . 22

**7 REFERENCES** **24**

# List of Figures

1 Danh sách cột bị thiếu . . . . . 6
2 Thống kê của các thuộc tính bị loại. . . . . 8
3 Heatmap tương quan giữa các thành phần với SalePrice . . . . . 10
4 Tuyến tính giữa GrLivArea và SalePrice . . . . . 11
5 Chia Dataset thành Training và Validation set . . . . . 12
6 Đưa dữ liệu vào mô hình . . . . . 12
7 Đường hồi quy tuyến tính giữa GrLivArea và SalePrice trên tập kiểm định . . . . . 12
8 Biểu đồ sai số (Residual Plot) kiểm tra độ lệch của mô hình . . . . . 13
9 Heatmap tương quan giữa các thành phần với SalePrice . . . . . 16
10 Chia dữ liệu thành training và validation set . . . . . 17
11 Biểu đồ độ quan trọng của các đặc trưng trong Random Forest . . . . . 17
12 So sánh giá trị dự đoán và giá trị thực tế . . . . . 18
13 Biểu đồ so sánh hiệu năng (RMSE và R-squared) giữa Linear Regression và Random Forest 20
14 Trực quan hóa mức độ quan trọng của các đặc trưng (Feature Importance) . . . . . 21

# List of Tables

1 Member list & workload . . . . . 4

# Member list & Workload

| No. | Fullname | Student ID | Problems | % done |
|---|---|---|---|---|
| 1 | Nguyễn Xuân Huy Hoàng | 2311070 | - Hoàn thành so sánh mô hình và Visualize kết quả | 100% |
| 2 | Phan Đăng Nhật Huy | 2311226 | - Hoàn thành xử lý, lọc dữ liệu đầu vào và phân chia tập dữ liệu | 100% |
| 3 | Sẻ Thế Hưng | 2053079 | - Hoàn thành thuật toán Linear Regression và Random forest | 100% |

Table 1: Member list & workload

# 1 Giới thiệu tổng quan

## 1.1 Đặt vấn đề và Lý do chọn đề tài

Bất động sản từ lâu đã là một trong những kênh đầu tư và tài sản quan trọng với hầu hết mọi người. Tuy nhiên, việc xác định giá trị thực sự của một căn nhà không phải lúc nào cũng đơn giản - giá nhà phụ thuộc vào rất nhiều yếu tố khác nhau, từ diện tích và chất lượng xây dựng cho đến vị trí, tiện nghi xung quanh, và cả thời điểm giao dịch. Có thể thấy, việc định giá một căn nhà là một việc rất khó khăn với những người thiếu kinh nghiệm.

Đó cũng là lý do mà nhóm đã chọn đề tài này. Bằng cách ứng dụng các kỹ thuật `Data Mining` và `Machine Learning`, nhóm kỳ vọng có thể xây dựng một mô hình dự đoán giá nhà dựa trên dữ liệu thực tế.

Source code của dự án có thể tìm thấy ở Link.

## 1.2 Mô tả tập dữ liệu

Tập dữ liệu được sử dụng đến từ cuộc thi "*House Prices: Advanced Regression Techniques*" trên `Kaggle`, tập trung vào thị trường bất động sản tại thành phố `Ames`, `Iowa`. Tập dữ liệu bao gồm 2919 mẫu, gồm 1460 mẫu trong tập huấn luyện và 1459 mẫu trong tập kiểm tra, mỗi mẫu tương ứng với một căn nhà tại thành phố `Ames`, `Iowa`, Hoa Kỳ, được giao dịch trong giai đoạn 2006–2010. Điểm đặc biệt của tập dữ liệu này là nó có tới 79 thuộc tính đầu vào, bao gồm cả biến định lượng lẫn định tính, phản ánh gần như mọi khía cạnh của một căn nhà. Một số thuộc tính quan trọng:

- *SalePrice:* Đây là giá bán thực tế của căn nhà - con số mà chúng ta cần dự đoán.
- *OverallQual (Chất lượng tổng thể):* Một con số từ 1 đến 10 đánh giá xem căn nhà còn mới và tốt hay không. Đây thường là yếu tố "quyết định" nhất đến giá tiền.
- *GrLivArea (Diện tích sử dụng):* Diện tích phần không gian sống trên mặt đất. Nhà càng rộng thì giá thường càng cao.
- *YearBuilt:* Năm căn nhà được xây dựng, giúp ta biết được độ cũ/mới của công trình.

## 1.3 Mục tiêu cụ thể

Nghiên cứu này tập trung vào việc thực hiện quy trình khai phá dữ liệu toàn diện nhằm đạt được các mục tiêu sau:

1. **Tiền xử lý và Feature Engineering:** Giải quyết các vấn đề về dữ liệu thiếu, nhiễu, và chuẩn hóa phân phối của dữ liệu.
2. **Xây dựng mô hình dự đoán:** Thử nghiệm và đánh giá hiệu năng của các thuật toán khác nhau như Linear Regression, Random Forest...
3. **Phân tích tương quan:** Xác định và đánh giá các yếu tố cốt lõi có tác động mạnh mẽ nhất đến giá trị bất động sản.

# 2 Tiền xử lý dữ liệu

## 2.1 Làm sạch dữ liệu

Sử dụng lệnh `df.columns[df.isnull().any()]` ta thấy được các cột có giá trị khuyết.

```
train_df.columns[train_df.isnull().any()]
test_df.columns[test_df.isnull().any()]
✓ 0.1s

Index(['LotFrontage', 'Alley', 'MasVnrType', 'MasVnrArea', 'BsmtQual',
       'BsmtCond', 'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2',
       'Electrical', 'FireplaceQu', 'GarageType', 'GarageYrBlt',
       'GarageFinish', 'GarageQual', 'GarageCond', 'PoolQC', 'Fence',
       'MiscFeature'],
      dtype='str')

Index(['MSZoning', 'LotFrontage', 'Alley', 'Utilities', 'Exterior1st',
       'Exterior2nd', 'MasVnrType', 'MasVnrArea', 'BsmtQual', 'BsmtCond',
       'BsmtExposure', 'BsmtFinType1', 'BsmtFinSF1', 'BsmtFinType2',
       'BsmtFinSF2', 'BsmtUnfSF', 'TotalBsmtSF', 'BsmtFullBath',
       'BsmtHalfBath', 'KitchenQual', 'Functional', 'FireplaceQu',
       'GarageType', 'GarageYrBlt', 'GarageFinish', 'GarageCars', 'GarageArea',
       'GarageQual', 'GarageCond', 'PoolQC', 'Fence', 'MiscFeature',
       'SaleType'],
      dtype='str')
```

Figure 1: Danh sách cột bị thiếu

Dễ thấy tập dữ liệu đang có rất nhiều thuộc tính đang có dữ liệu bị thiếu. Đặc biệt khi dùng `df.info()` ta thấy PoolQC chỉ có 3 giá trị. Để đảm bảo tính toàn vẹn của dữ liệu trước khi đưa vào mô hình huấn luyện, nhóm đã thực hiện quy trình xử lý giá trị thiếu dựa trên đặc thù ý nghĩa của từng nhóm thuộc tính. Quy trình cụ thể như sau:

### 2.1.1 Xử lý theo nhóm đặc tính

- **Nhóm thuộc tính tiện ích:** Đối với các biến như PoolQC, MiscFeature, Alley, Fence, FireplaceQu và các biến liên quan đến Garage, Basement, giá trị thiếu được điền là "None". Phản ánh thực tế rằng căn nhà đó không có các tiện ích tương ứng
- **Nhóm thuộc tính số học:** Các biến như GarageCars, GarageArea, BsmtFinSF1, BsmtFinSF2, TotalBsmtSF, BsmtFullBath... được điền bằng giá trị 0 nếu dữ liệu bị khuyết.
- **Điền theo giá trị phổ biến:** Với các biến có mang tính chất phân loại khu vực như MSZoning, Electrical, Exterior1st, KitchenQual, SaleType, giá trị xuất hiện thường xuyên nhất của cột đó được sử dụng để lấp đầy khoảng trống.

### 2.1.2 Xử lý theo logic phụ thuộc và thống kê khu vực

Một số thuộc tính đòi hỏi phương pháp xử lý phức tạp hơn để giữ được tính phân hóa của dữ liệu:

- **LotFrontage (Chiều dài mặt tiền):** Do kích thước mặt tiền thường tương đồng trong cùng một khu vực, nhóm sử dụng giá trị trung vị của các căn nhà trong cùng Neighborhood để điền vào các vị trí thiếu.
- **GarageYrBlt (Năm xây gara):** Trong trường hợp giá trị này bị thiếu, nhóm giả định gara được xây cùng lúc với căn nhà và sử dụng giá trị của cột *YearBuilt* để thay thế.
- **MasVnr (Lớp vỏ trang trí):** Nhóm áp dụng xử lý có điều kiện:
  + Nếu MasVnrArea $> 0$ nhưng loại vỏ Type bị thiếu, điền loại vỏ phổ biến nhất khác "None".
  + Nếu diện tích Area bị thiếu nhưng đã có loại vỏ, sử dụng diện tích trung bình của loại vỏ đó để điền vào.
  + Các trường hợp còn lại mặc định về "None" và 0.

## 2.2 Chuyển đổi dữ liệu

Sau khi xử lý các giá trị thiếu, các thuộc tính phân loại cần được chuyển đổi sang dạng số để các thuật toán máy học có thể tính toán. Trong bài toán này, nhóm đã áp dụng hai chiến lược mã hóa khác nhau tùy thuộc vào bản chất của dữ liệu:

### 2.2.1 Mã hóa thứ tự (Ordinal Encoding)

Một đặc điểm quan trọng của tập dữ liệu giá nhà Ames là có rất nhiều thuộc tính thể hiện mức độ đánh giá (ví dụ: Chất lượng từ "Tồi" đến "Xuất sắc"). Để giữ được mối quan hệ thứ bậc này, nhóm đã thực hiện ánh xạ thủ công các giá trị chữ thành các con số tương ứng.

- **Nhóm đánh giá chất lượng:** Các biến như ExterQual, HeatingQC, KitchenQual... được ánh xạ từ 0 đến 5 tương ứng với các mức độ: *None* (0), *Po* (1), *Fa* (2), *TA* (3), *Gd* (4), *Ex* (5).
- **Nhóm đặc tính kỹ thuật:**
  + *BsmtFinType*: Được mã hóa từ 0 (None) đến 6 (GLQ).
  + *Functional*: Mã hóa mức độ hoạt động của căn nhà từ 0 (Sal - hư hỏng nặng) đến 7 (Typ - bình thường).
  + *CentralAir, PavedDrive, Fence*: Chuyển đổi sang dạng số dựa trên sự tồn tại hoặc mức độ kiên cố của tiện ích.

### 2.2.2 Mã hóa biến giả (One-Hot Encoding)

Đối với các biến phân loại còn lại không có tính chất thứ bậc rõ rệt (ví dụ: Neighborhood, MSZoning, Foundation), nhóm sử dụng phương pháp One-Hot Encoding chuyển giá trị phân loại thành một cột riêng biệt với giá trị nhị phân (0 hoặc 1). Nhóm đã sử dụng tham số `drop_first=True` để loại bỏ cột đầu tiên trong mỗi nhóm biến mới, nhằm tránh hiện tượng đa cộng tuyến (Multicollinearity).

## 2.3 Chuẩn hóa dữ liệu

Nhóm sử dụng kỹ thuật `StandardScaler` để đưa các thuộc tính số học về cùng một thang đo với trung bình bằng 0 và độ lệch chuẩn bằng 1. Công thức chuẩn hóa:

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

Để tránh rò rỉ thông tin (Data Leakage), chúng ta sử dụng `fit()` trên tập huấn luyện rồi transform trên cả hai tập dữ liệu thay vì gộp hai tập dữ liệu rồi chuẩn hóa.

## 2.4 Trích xuất đặc trưng

Nhằm giúp mô hình học tốt hơn và cho kết quả tốt hơn. Nhóm tiến hành trích xuất và lựa chọn đặc trưng:

### 2.4.1 Loại bỏ các thuộc tính ít giá trị

Nhóm thực hiện loại bỏ các cột dữ liệu có tỉ lệ khuyết thiếu quá cao hoặc độ lệch dữ liệu (*data imbalance*) quá lớn như: *Utilities, Street, PoolQC, LowQualFinSF*. Việc loại bỏ các biến "nhiễu" này giúp mô hình tập trung vào các thuộc tính thực sự có khả năng giải thích sự biến động của giá nhà.

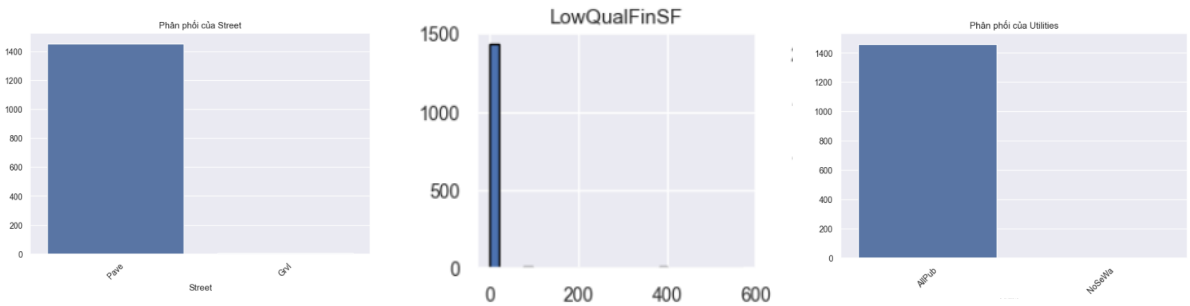


Figure 2: Thống kê của các thuộc tính bị loại.

### 2.4.2 Tạo lập các biến tổng hợp

Thay vì để các thông số rời rạc, nhóm xây dựng các biến tổng hợp nhằm phản ánh quy mô toàn diện của căn nhà:

- **TotalSF (Tổng diện tích):** Được tính bằng tổng diện tích tầng hầm TotalBsmtSF, tầng một 1stFlrSF và tầng hai 2ndFlrSF.
- **Total_Bathrooms (Tổng số phòng tắm):** Nhóm thực hiện quy đổi các phòng tắm phụ HalfBath thành 0.5 đơn vị để tạo ra một biến số thực thể hiện chính xác tiện nghi của căn nhà.

### 2.4.3 Đặc trưng về thời gian và trạng thái

- **HouseAge và RemodAge:** Thay vì sử dụng năm xây dựng gốc, nhóm tính toán "Tuổi thọ" của căn nhà và khoảng thời gian từ lần sửa chữa cuối cùng đến khi bán. Nhà càng mới hoặc vừa mới sửa chữa thường có giá trị cao hơn.
- **Biến trạng thái (Boolean):** Chuyển đổi các cột số lượng thành các biến đánh dấu `0` hoặc `1` (Ví dụ: *HasFireplace*) để mô hình dễ dàng nhận diện sự hiện diện của các tiện ích cao cấp.

#### 2.4.4 Biến tương tác

Để nắm bắt các mối quan hệ phi tuyến tính, nhóm tạo ra các biến như `Qual_x_TotalSF`. Điều này dựa trên thực tế rằng diện tích lớn chỉ thực sự có giá trị cao khi đi kèm với chất lượng xây dựng tốt.

#### 2.4.5 Giảm lệch

Cuối cùng, nhóm áp dụng Log Transformation cho các biến diện tích (*TotalSF, GrLivArea, LotArea*) để giảm độ lệch.

# 3 Mô hình hoá cơ sở - kỹ thuật trong đề cương

## 3.1 Lựa chọn thuật toán

Trong quá trình xây dựng mô hình cơ sở, nhóm lựa chọn **Hồi quy tuyến tính đơn giản (Simple Linear Regression)**. Đây là một thuật toán nền tảng trong học máy, thường được sử dụng để thiết lập baseline trước khi thử nghiệm các mô hình phức tạp hơn.

Nhóm sẽ sử dụng Heatmap tương quan để quan sát sự tương quan giữa các thành phần với SalePrice.

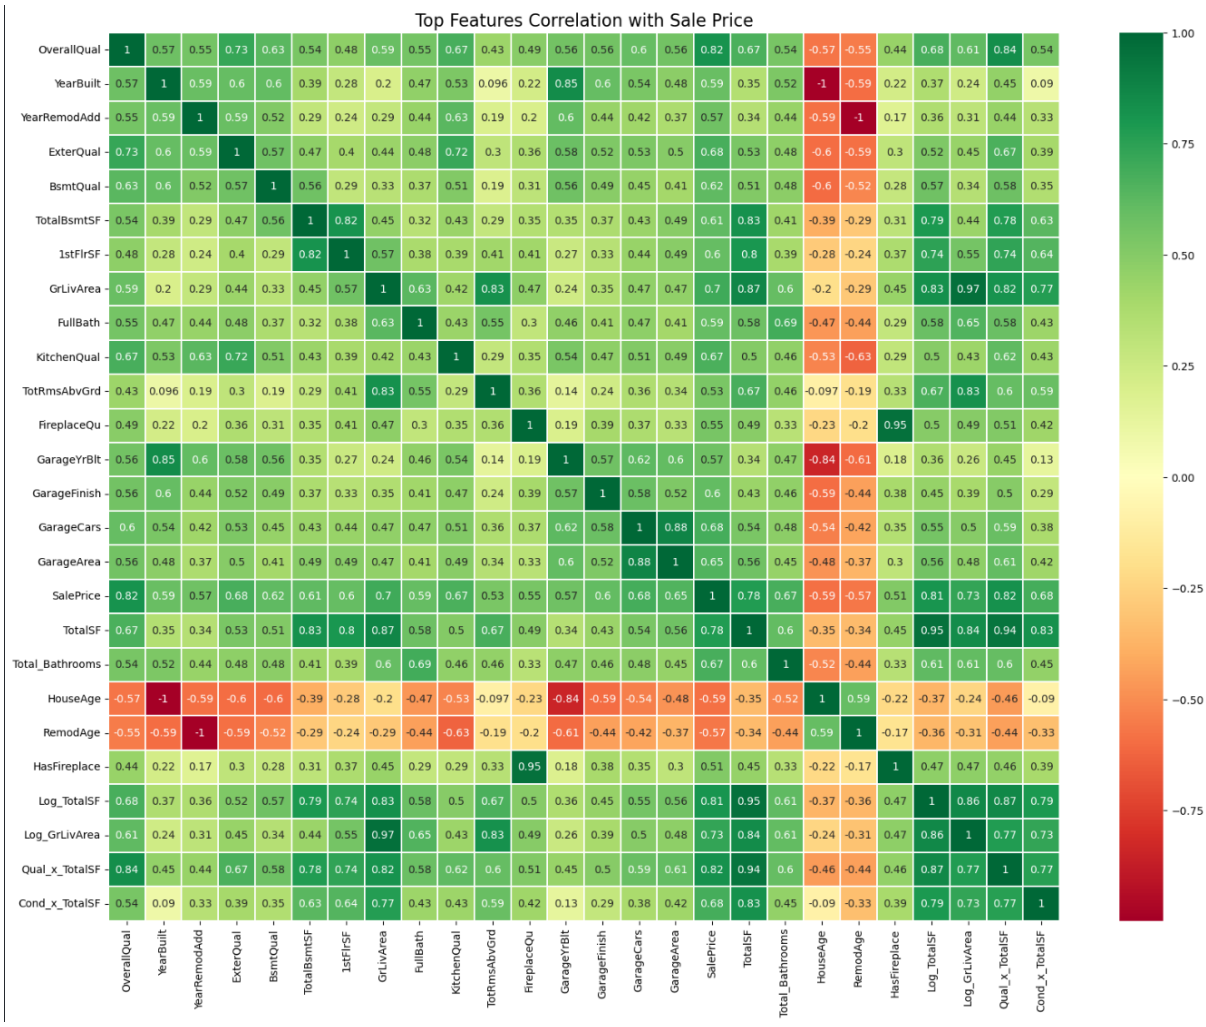


Figure 3: Heatmap tương quan giữa các thành phần với SalePrice

Sau khi quan sát biểu đồ Heatmap thì một số biến có độ tương quan với SalePrice vượt ngưỡng 0.7 là: Qual_x_TotalSF (0,82), Log_GrLivArea (0.73), Log_TotalSF (0.81), TotalSF (0.78), GrLivArea (0.7), OverallQual (0.82).

### 3.1.1 Cơ sở lựa chọn:

- Qua phân tích biểu đồ tương quan, nhiều biến có hệ số tương quan cao với SalePrice như OverallQual, TotalSF, Log_TotalSF. Tuy nhiên, các biến này phần lớn là kết quả của quá trình tiền xử lý hoặc kết hợp nhiều đặc trưng. Để đảm bảo tính đơn giản, trực quan và dễ diễn giải, nhóm đã lựa chọn GrLivArea - một đặc trưng gốc phản ánh diện tích sinh hoạt

- Nhóm sau đó sử dụng thêm biểu đồ phân tán (scatter plot) giữa GrLivArea và SalePrice để minh họa xu hướng tuyến tính rõ rệt: khi diện tích sinh hoạt càng lớn thì giá bán nhà càng cao.

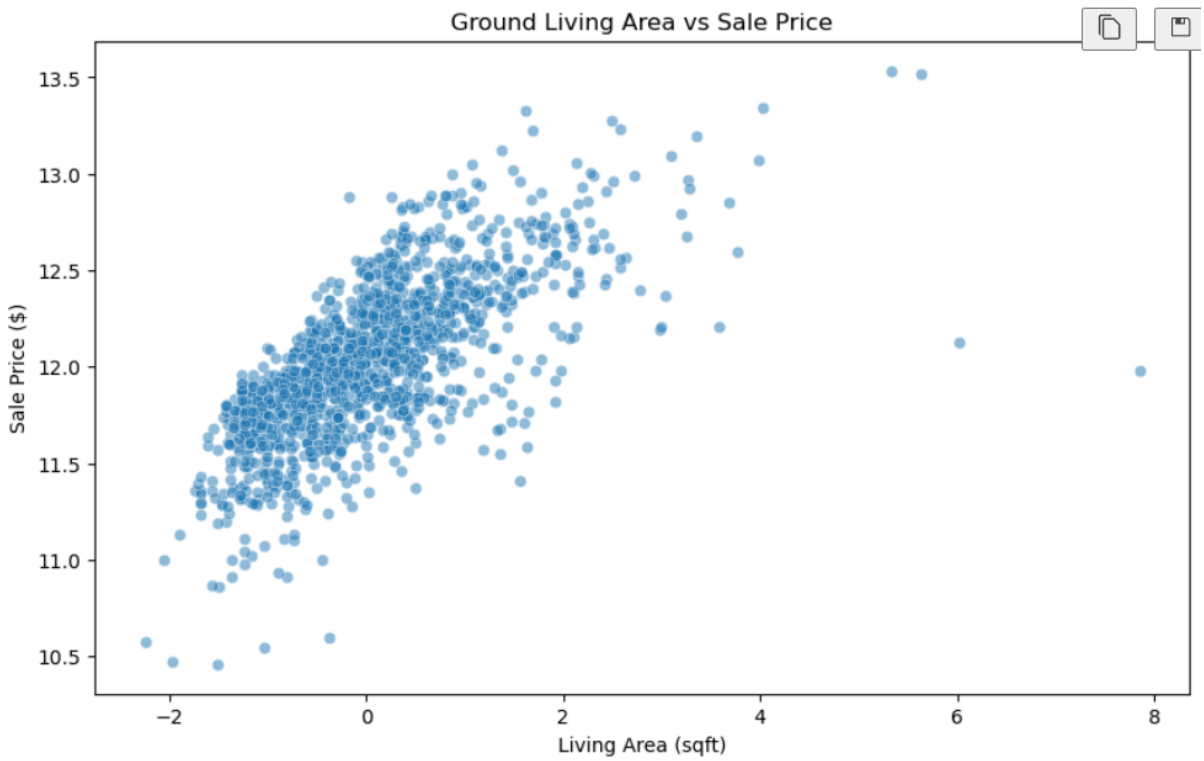


Figure 4: Tuyến tính giữa GrLivArea và SalePrice

- Do mối quan hệ tuyến tính nổi bật, nhóm lựa chọn **Hồi quy tuyến tính đơn giản (Simple Linear Regression)** làm mô hình cơ sở.
- Đây là thuật toán nền tảng, dễ triển khai và dễ diễn giải, phù hợp để thiết lập baseline trước khi thử nghiệm các mô hình phức tạp hơn.

#### 3.1.2 Ý nghĩa của việc chọn mô hình cơ sở:

- Thiết lập chuẩn mực ban đầu để so sánh hiệu quả cải thiện khi áp dụng các mô hình đa biến hoặc phi tuyến tính.
- Kiểm chứng giả thuyết rằng diện tích sinh hoạt là một yếu tố quan trọng trong việc định giá nhà.
- Cho phép trực quan hóa mối quan hệ giữa biến đầu vào và biến mục tiêu, từ đó phát hiện những giới hạn của mô hình này.

### 3.2 Huấn luyện và Đánh giá

#### 3.2.1 Quá trình huấn luyện:

- Dataset sẽ được chia thành Training set (80%) và Validation set (20%).

```
X = train_clean[['GrLivArea']]
y = train_clean['SalePrice']

X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Training set size: {X_train.shape}")
print(f"Validation set size: {X_val.shape}")
```

Figure 5: Chia Dataset thành Training và Validation set

- Sau khi thực hiện chia dữ liệu thành các tập training và validation thì nhóm đưa dữ liệu vào mô hình để huấn luyện.

```
baseline_reg = LinearRegression()
baseline_reg.fit(X_train, y_train)
```

Figure 6: Đưa dữ liệu vào mô hình

- Sau khi huấn luyện, mô hình được dùng để dự đoán giá nhà trên tập dữ liệu kiểm định.

### 3.2.2 Trực quan hóa kết quả mô hình:

- Để kiểm chứng hiệu quả của mô hình hồi quy tuyến tính đơn giản, nhóm biểu diễn đường hồi quy (regression line) trên tập kiểm định và phân tích sai số qua biểu đồ sai số (residual plot).

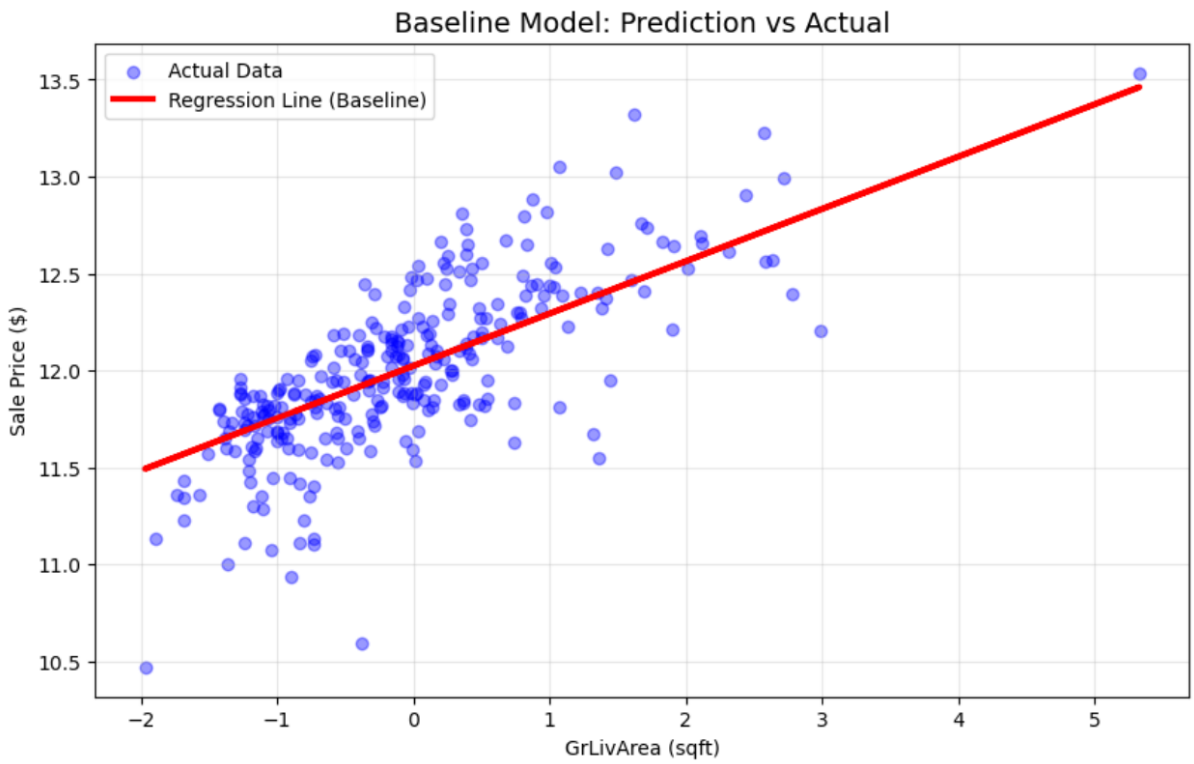


Figure 7: Đường hồi quy tuyến tính giữa GrLivArea và SalePrice trên tập kiểm định

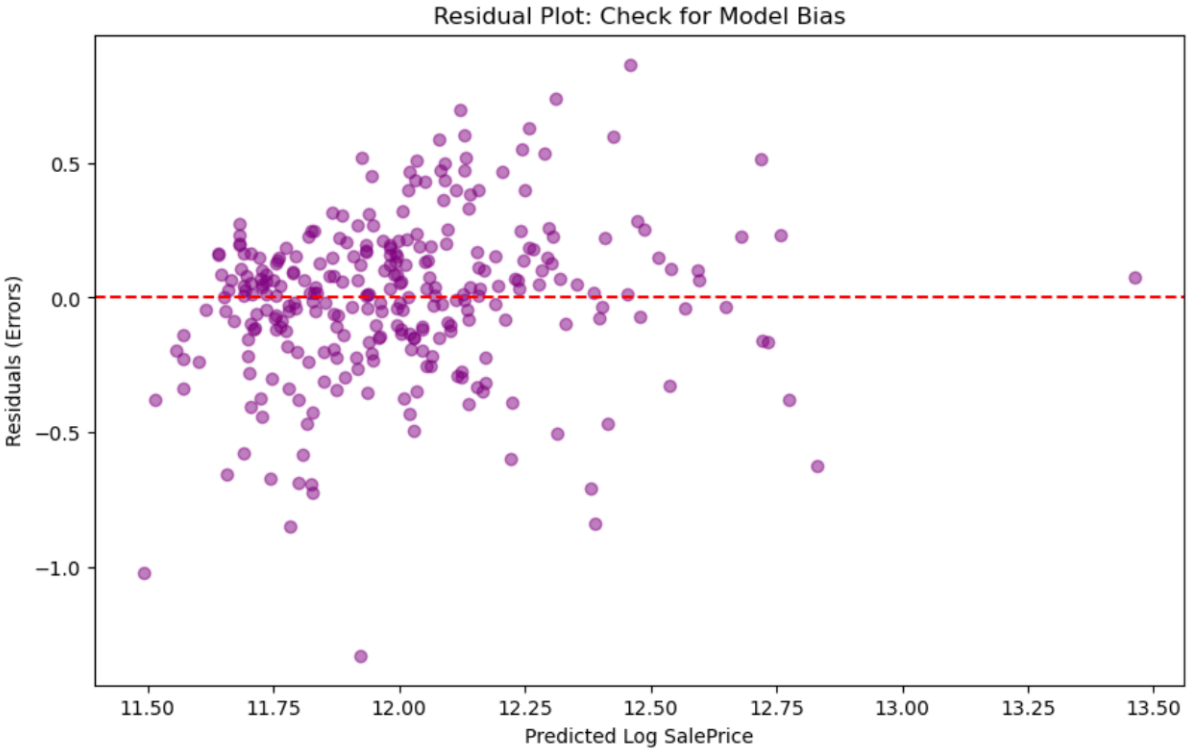


Figure 8: Biểu đồ sai số (Residual Plot) kiểm tra độ lệch của mô hình

#### 3.2.3 Kết quả đánh giá:

- Nhóm sẽ sử dụng công thức RMSE (Root Mean Squared Error) để đo lường độ lệch trung bình giữa giá trị dự đoán và giá trị thực tế và công thức R-squared để nhận biết mô hình giải thích được bao nhiêu phần trăm biến thiên của dữ liệu.
- Công thức RMSE:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2}$$

- Công thức R-Squared:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{3}$$

- RMSE (Root Mean Squared Error): $58,137.54
- R-Squared: 0.5402

#### 3.2.4 Diễn giải kết quả:

- Mô hình giải thích được khoảng 54% sự biến thiên của giá nhà, xác nhận rằng diện tích sinh hoạt là một biến dự báo mạnh.
- Tuy nhiên, sai số trung bình khoảng $58k là khá lớn, cho thấy mô hình bỏ qua nhiều yếu tố quan trọng khác.
- Biểu đồ residual cho thấy sai số phân tán rộng, chứng minh rằng mô hình tuyến tính đơn biến chưa đủ để mô tả toàn bộ dữ liệu.

## 3.3 Nhận xét giới hạn của mô hình cơ sở

### 3.3.1 Những giới hạn chính:

1. Đơn biến:
   - Mô hình chỉ sử dụng một đặc trưng duy nhất (GrLivArea).
   - Bỏ qua các yếu tố quan trọng khác như chất lượng xây dựng (OverallQual), tổng diện tích (TotalSF), vị trí địa lý, tuổi thọ căn nhà, số phòng, ...
2. Giả định tuyến tính:
   - Hồi quy tuyến tính đơn giản giả định mối quan hệ tuyến tính hoàn toàn giữa diện tích sinh hoạt và giá nhà.
   - Thực tế, giá nhà thường chịu ảnh hưởng phi tuyến tính và tương tác giữa nhiều biến.
3. Sai số cao:
   - RMSE $58k là mức sai số lớn, không đủ để ứng dụng trong thực tế.
   - Biểu đồ residual cho thấy sai số phân tán rộng, chứng minh mô hình chưa nắm bắt hết cấu trúc dữ liệu.
4. Khả năng khái quát hạn chế:
   - Mô hình cơ sở chỉ phù hợp để minh họa xu hướng tổng quát, không thể dự đoán chính xác cho từng trường hợp cụ thể.

### 3.3.2 Chiến lược cải thiện:

- **Hồi quy đa biến:** Kết hợp nhiều đặc trưng có tương quan cao với SalePrice.
- **Thuật toán phi tuyến tính:** Áp dụng Random Forest, Gradient Boosting hoặc XGBoost để nắm bắt quan hệ phức tạp.
- **Feature engineering:** Sử dụng các biến đã qua xử lý (log-transform, kết hợp đặc trưng) để giảm sai số.

# 4 Mô hình hóa nâng cao

## 4.1 Lựa chọn kỹ thuật

Trong giai đoạn mô hình hóa nâng cao, nhóm lựa chọn Random Forest Regressor – một thuật toán thuộc nhóm Ensemble Learning. Random Forest hoạt động bằng cách xây dựng nhiều cây quyết định (Decision Trees) trên các tập dữ liệu con khác nhau, sau đó kết hợp kết quả dự đoán của chúng để đưa ra giá trị cuối cùng

### 4.1.1 Cơ sở lựa chọn:

- **Khả năng nắm bắt quan hệ phi tuyến tính:** Khác với hồi quy tuyến tính đơn giản, Random Forest có thể mô hình hóa các mối quan hệ phức tạp và phi tuyến tính giữa nhiều đặc trưng và giá nhà.
- **Giảm thiểu overfitting:** Nhờ cơ chế bootstrap sampling và bagging, Random Forest thường ổn định hơn so với một cây quyết định đơn lẻ.
- **Khai thác đa biến:** Mô hình cho phép sử dụng nhiều đặc trưng cùng lúc (ví dụ: OverallQual, TotalSF, GrLivArea, các biến log-transform), từ đó tận dụng tối đa thông tin trong dữ liệu.
- **Phân tích độ quan trọng đặc trưng (Feature Importance):** Random Forest cung cấp thước đo định lượng cho thấy đặc trưng nào ảnh hưởng mạnh nhất đến giá nhà, giúp mô hình vừa chính xác vừa dễ diễn giải.

### 4.1.2 Ý nghĩa học thuật:

- Việc lựa chọn Random Forest thể hiện bước chuyển từ mô hình cơ sở đơn giản sang mô hình nâng cao, có khả năng cải thiện đáng kể độ chính xác.
- Đây là một trong những thuật toán phổ biến và mạnh mẽ nhất trong các bài toán dự đoán giá nhà.

## 4.2 Quá trình huấn luyện

### 4.2.1 Thiết lập tham số:

- Mô hình được khởi tạo với Random Forest Regressor gồm 100 cây quyết định (decision tree) (`n_estimators = 100`).
- Sử dụng `random_state = 42` để đảm bảo tính tái lập kết quả.
- Tham số `n_jobs = -1` cho phép tận dụng toàn bộ lõi CPU để tăng tốc độ huấn luyện.

### 4.2.2 Quá trình huấn luyện:

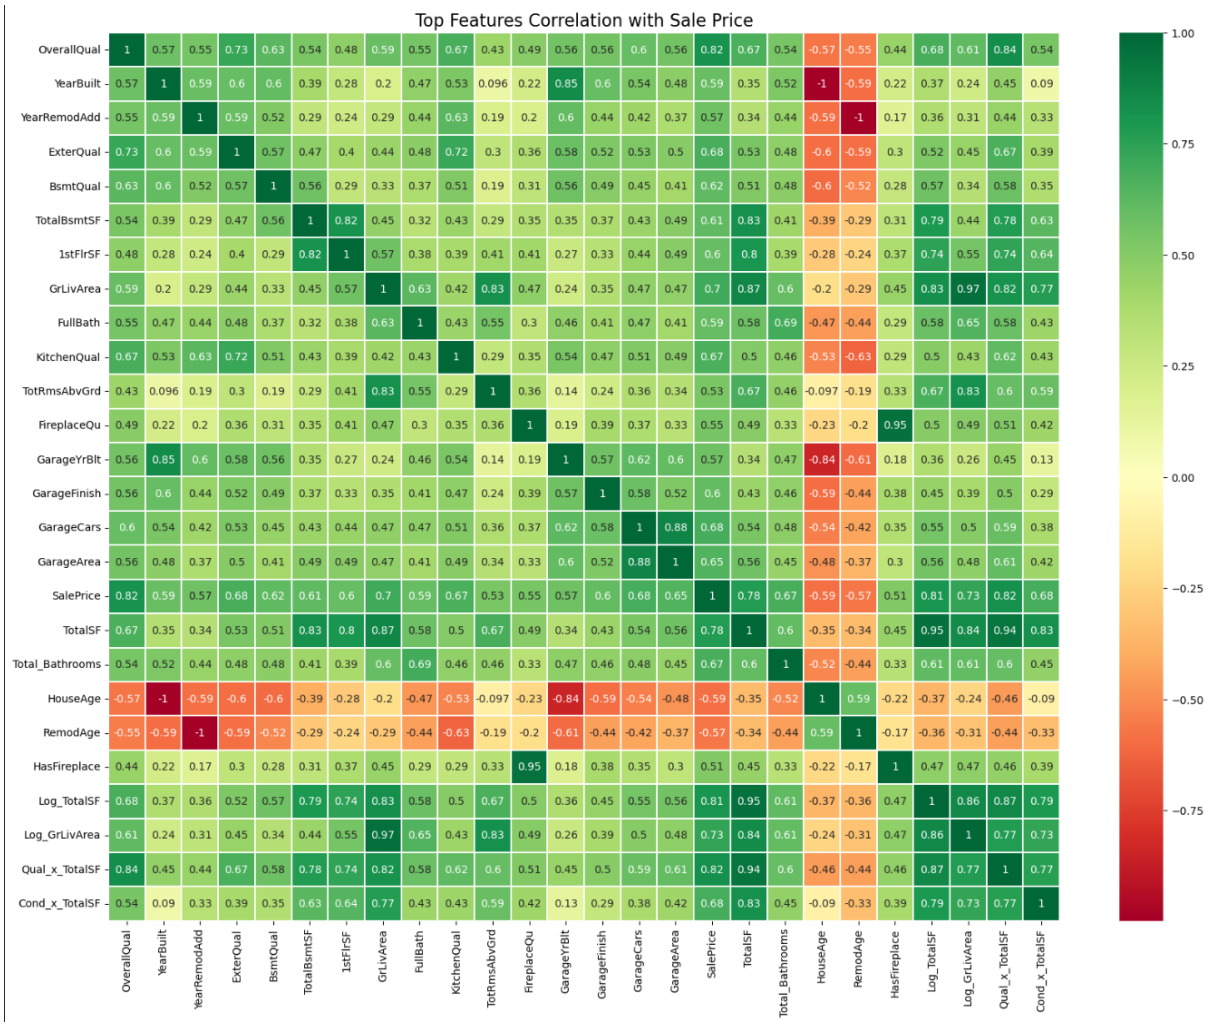


Figure 9: Heatmap tương quan giữa các thành phần với SalePrice

1. **Chọn đặc trưng:** Dựa trên phân tích tương quan, nhóm lựa chọn các biến có hệ số tương quan cao với SalePrice như:
   - Qual_x_TotalSF (0.82)
   - Log_GrLivArea (0.73)
   - Log_TotalSF (0.81)
   - TotalSF (0.78)
   - GrLivArea (0.7)
   - OverallQual (0.82)
2. **Chia tập dữ liệu:** Sau đó tiến hành tách dữ liệu ra thành Training và Validation set để đưa vào mô hình huấn luyện.

```python
# 1. Chọn danh sách Features dựa trên Heatmap (Correlation > 0.7)
advanced_features = [
    'OverallQual', # 0.82
    'Qual_x_TotalSF', # 0.82
    'Log_GrLivArea', # 0.73
    'Log_TotalSF', # 0.81
    'TotalSF', # 0.78
    'GrLivArea', # 0.70
]

X = train_clean[advanced_features]
y = train_clean['SalePrice']

# 2. Chia dữ liệu Train/Validation
X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Selected the top {len(advanced_features)} most significant features.")
print(f"Training set shape: {X_train.shape}")
```

Figure 10: Chia dữ liệu thành training và validation set

3 **Huấn luyện mô hình:** Fit Random Forest trên tập huấn luyện để học mối quan hệ giữa các đặc trưng và giá nhà.

4 **Dự đoán:** Thực hiện dự đoán trên tập kiểm định, kết quả được chuyển đổi về đơn vị USD thực tế để so sánh với mô hình cơ sở.

- RMSE: $32,201.12
- Kết quả dự đoán trên tập kiểm định cho thấy mô hình Random Forest đã cải thiện đáng kể so với mô hình cơ sở.

#### 4.2.3 Phân tích độ quan trọng đặc trưng:

Sau khi huấn luyện, nhóm sử dụng thuộc tính feature_importances_ để xác định mức độ đóng góp của từng đặc trưng vào mô hình.

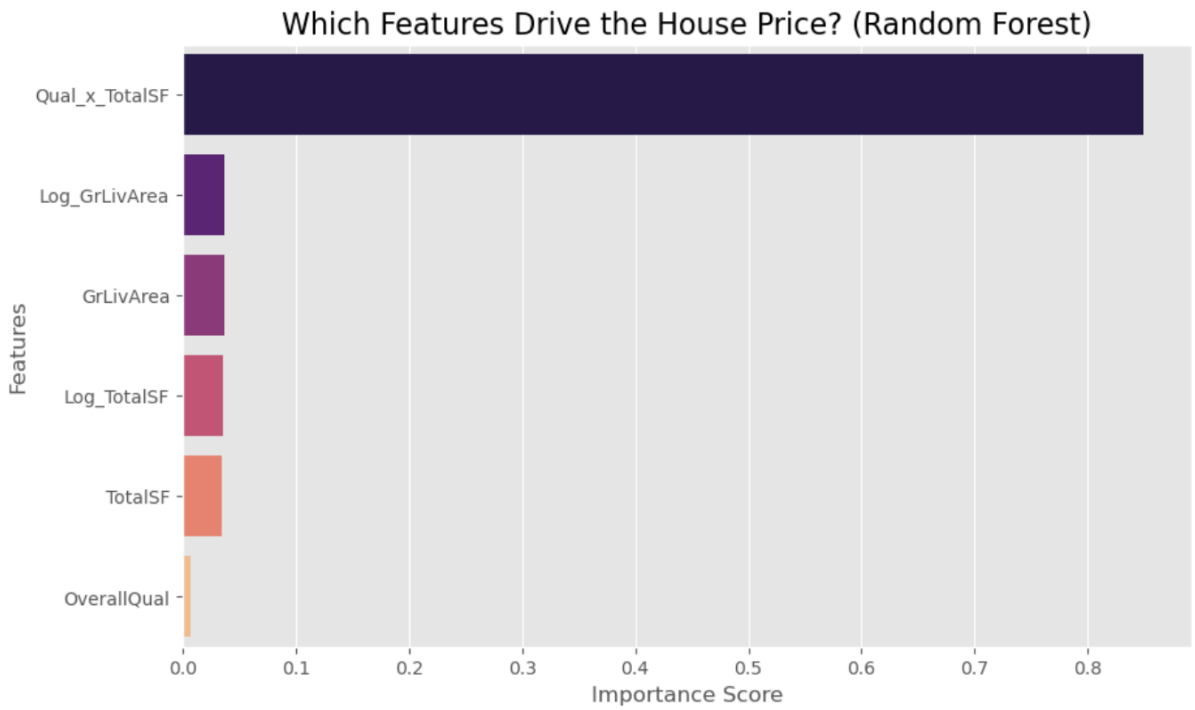


Figure 11: Biểu đồ độ quan trọng của các đặc trưng trong Random Forest

- Biểu đồ độ quan trọng cho thấy OverallQual (chất lượng tổng thể) và TotalSF (tổng diện tích) là hai yếu tố chi phối mạnh nhất đến giá nhà.
- GrLivArea vẫn có vai trò quan trọng, nhưng không còn là đặc trưng mạnh nhất như trong mô hình cơ sở.
- Các biến đã qua xử lý như Log_TotalSF và Qual_x_TotalSF cũng đóng góp đáng kể, chứng minh rằng việc tiền xử lý và tạo đặc trưng mới giúp mô hình nâng cao nắm bắt dữ liệu tốt hơn.

## 4.3 Kết quả đánh giá mô hình nâng cao

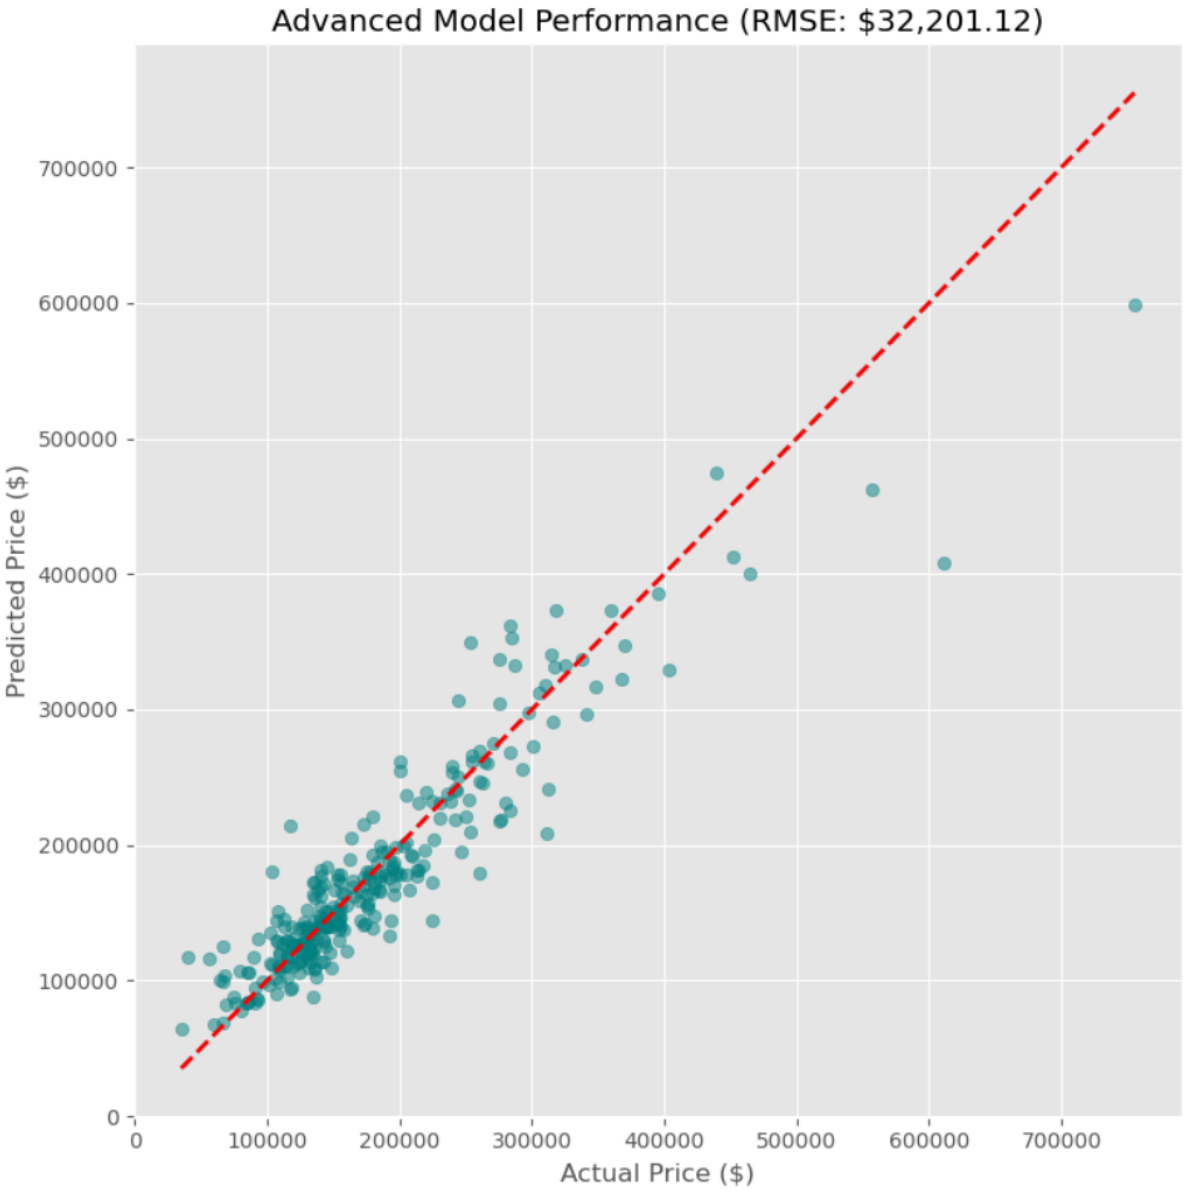


Figure 12: So sánh giá trị dự đoán và giá trị thực tế

### 4.3.1 Kết quả đánh giá:

- RMSE của RandomForest: $32,201.12
- RMSE của Baseline (Linear Regression): $58,137.54

- Mô hình RandomForest đã giảm $26,000 so với mô hình cơ sở.

#### 4.3.2 Nhận xét:

- Scatter plot minh họa rằng các điểm dự đoán nằm gần đường chéo (Actual = Predicted), chứng tỏ mô hình có độ chính xác cao hơn và sai số giảm.
- Việc giảm RMSE từ 58k xuống 32k là một bước nhảy lớn, khẳng định hiệu quả của việc kết hợp nhiều đặc trưng và sử dụng mô hình phi tuyến tính
- Phân tích độ quan trọng đặc trưng cho thấy OverallQual và TotalSF là yếu tố chi phối mạnh nhất đến giá nhà, trong khi GrLivArea chỉ đóng vai trò bổ sung.
- Như vậy, mô hình nâng cao không chỉ cải thiện hiệu suất dự đoán mà còn mang lại insight thực tế: chất lượng xây dựng và tổng diện tích là yếu tố quyết định giá trị bất động sản.

# 5 So sánh, trực quan hóa và khai phá tri thức

## 5.1 Trực quan hóa và So sánh hiệu năng

Để đánh giá hiệu quả của việc áp dụng các kỹ thuật học máy nâng cao, nhóm tiến hành so sánh hiệu năng giữa mô hình cơ sở (Baseline Model - Linear Regression) và mô hình nâng cao (Advanced Model - Random Forest).

Mô hình hồi quy tuyến tính đơn giản (chỉ sử dụng `GrLivArea`) cho thấy mức độ giải thích dữ liệu ở mức trung bình với $R^2 \approx 0.5402$ và sai số RMSE lên đến 58,137.54 USD. Điều này phản ánh rõ hạn chế của việc chỉ sử dụng một đặc trưng diện tích đơn lẻ để dự đoán một biến mục tiêu phức tạp như giá nhà.

Ngược lại, mô hình Random Forest (với tập đặc trưng đa dạng và khả năng nắm bắt các mối quan hệ phi tuyến tính) đã cải thiện đáng kể các chỉ số đánh giá. Việc giảm mạnh RMSE và tăng $R^2$ chứng minh rằng thuật toán tập hợp (Ensemble Learning) giúp mô hình học được các mẫu phức tạp hơn, tránh hiện tượng quá khớp (overfitting) nhờ cơ chế lấy mẫu ngẫu nhiên (bootstrap) và kết hợp nhiều cây quyết định.

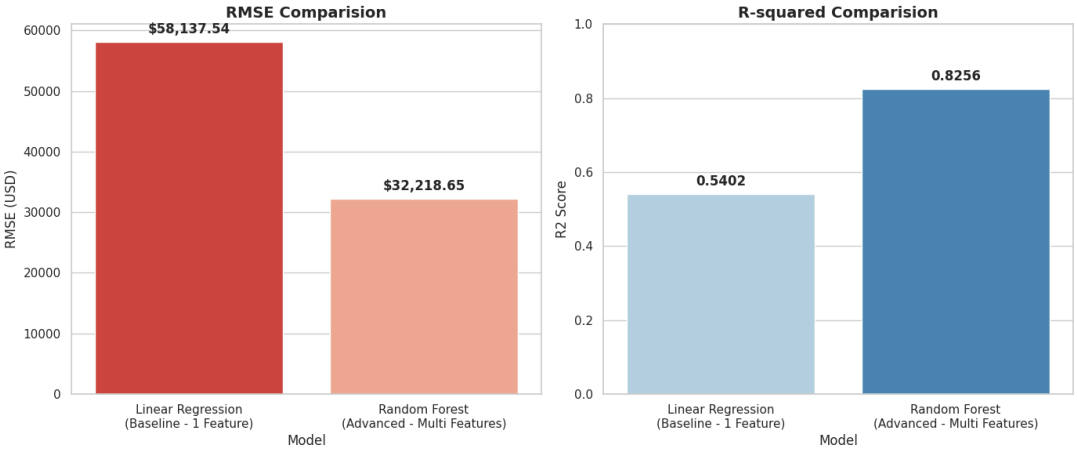


Figure 13: Biểu đồ so sánh hiệu năng (RMSE và R-squared) giữa Linear Regression và Random Forest

## 5.2 Khai phá tri thức

Thông qua thuộc tính `feature_importances_` của mô hình Random Forest, nhóm đã trích xuất và đo lường mức độ đóng góp của từng đặc trưng đối với giá trị căn nhà (`SalePrice`).

Kết quả phân tích cho thấy sự phân hóa rõ rệt:

- **Chất lượng tổng thể (`OverallQual`):** Đây là đặc trưng mang tính quyết định lớn nhất, chiếm hơn 48% mức độ ảnh hưởng đến giá nhà. Điều này cho thấy yếu tố thẩm mỹ, vật liệu hoàn thiện và tình trạng bảo trì đóng vai trò then chốt trong định giá bất động sản.
- **Các yếu tố về diện tích (`TotalSF`, `GrLivArea`):** Diện tích sử dụng thực tế (đặc biệt là không gian sống trên mặt đất và tổng diện tích khu vực) là nhóm yếu tố quan trọng thứ hai. Không gian rộng rãi luôn đi kèm với giá trị cơ bản của bất động sản.
- **Tối ưu nguồn lực dữ liệu:** Hệ thống định giá thực tế có thể dự đoán chính xác giá nhà chỉ bằng cách tập trung vào top 6-10 thông số quan trọng nhất thay vì phải

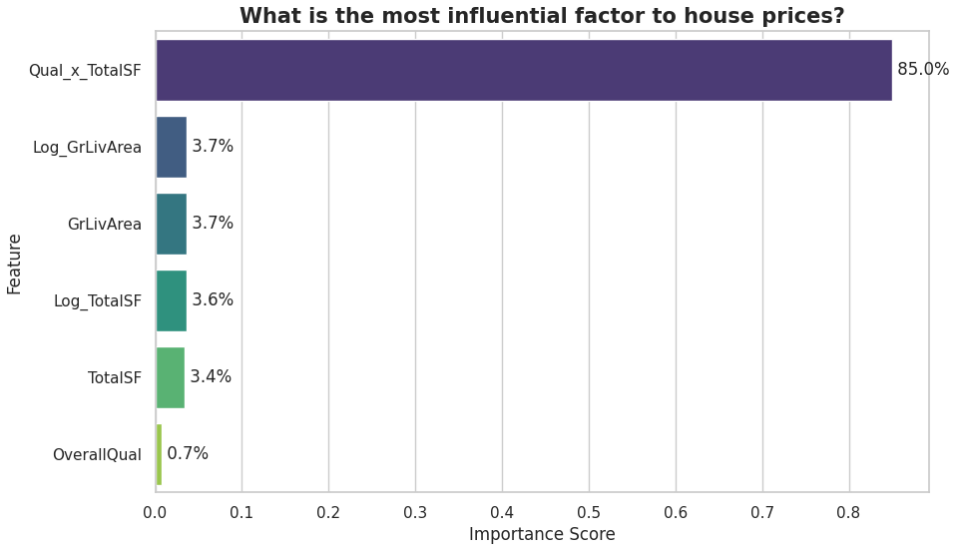


Figure 14: Trực quan hóa mức độ quan trọng của các đặc trưng (Feature Importance)

thu thập toàn bộ hơn 80 biến số ban đầu. Việc này giúp tiết kiệm đáng kể chi phí thu thập và xử lý dữ liệu.

# 6 Ra quyết định và kết luận

## 6.1 Tư vấn chiến lược kinh doanh

Từ những tri thức được khai phá từ mô hình học máy, đặc biệt là sự thống trị tuyệt đối của biến kết hợp `Qual_x_TotalSF` (chiếm 85% mức độ quan trọng), nhóm đề xuất các chiến lược kinh doanh thực tiễn sau:

- **Dành cho Người Bán và Nhà đầu tư (House Flippers):** Thuật toán chỉ ra rằng giá trị căn nhà được quyết định phần lớn bởi sự kết hợp tỷ lệ thuận giữa Chất lượng và Tổng diện tích. Thay vì tốn chi phí và thời gian xin giấy phép để cơi nới không gian sinh hoạt, nhà đầu tư nên tối ưu tỷ suất hoàn vốn (ROI) bằng cách phân bổ ngân sách để nâng cấp tối đa chất lượng vật liệu, ngoại thất và nội thất trên nền diện tích sẵn có. Một căn nhà có diện tích vừa phải nhưng vật liệu hoàn thiện cao cấp sẽ mang lại biên độ lợi nhuận và khả năng thanh khoản cao nhất.
- **Dành cho Người Mua nhà:** Đối với những gia đình có ngân sách hạn hẹp nhưng ưu tiên sự rộng rãi, chiến lược tối ưu là tìm mua những căn nhà có thông số diện tích tốt (`TotalSF`, `GrLivArea` cao) nhưng chất lượng hiện tại ở mức thấp hoặc trung bình. Vì biến kết hợp `Qual_x_TotalSF` đang ở mức thấp, căn nhà sẽ được định giá rẻ. Người mua có thể chốt giao dịch với giá hời, sau đó tự cải tạo nâng cấp chất lượng dần dần để kích hoạt sự tăng trưởng bứt phá về giá trị tài sản trong tương lai.

## 6.2 Kết luận

Dự án đã hoàn thành các mục tiêu được đặt ra ở Chương 1. Nhóm đã xây dựng thành công một pipeline khai phá dữ liệu hoàn chỉnh: từ khâu tiền xử lý, làm sạch, kỹ nghệ đặc trưng (Feature Engineering), đến việc huấn luyện và đánh giá mô hình.

Kết quả cho thấy sự vượt trội hoàn toàn của thuật toán Random Forest so với mô hình cơ sở (Linear Regression). Mô hình nâng cao đã tăng mức độ giải thích dữ liệu ($R^2$) từ 0.5402 lên 0.8256, đồng thời giảm mạnh sai số dự đoán (RMSE) từ $58,137.54$ USD xuống chỉ còn $32,218.65$ USD. Đặc biệt, hệ thống đã chứng minh tính tối ưu bằng cách rút gọn từ hơn 80 biến số thô ban đầu xuống chỉ cần tập trung vào top 6 thông số quan trọng nhất (nhóm diện tích và chất lượng) mà vẫn đảm bảo độ dự đoán chính xác cao. Thông qua dự án, các con số khô khan đã được chuyển hóa thành những tư vấn chiến lược mang tính thực tiễn, hỗ trợ trực tiếp quá trình ra quyết định trên thị trường.

## 6.3 Hướng phát triển tương lai

Dù mô hình hiện tại đã đạt được hiệu năng rất tốt, hệ thống vẫn còn không gian để cải thiện và mở rộng nếu có thêm thời gian và nguồn lực:

- **Thử nghiệm các thuật toán tiên tiến hơn:** Triển khai các thuật toán Gradient Boosting mạnh mẽ như XGBoost, LightGBM hoặc CatBoost, kết hợp với các kỹ thuật tinh chỉnh siêu tham số (Hyperparameter Tuning bằng GridSearchCV hoặc Optuna) để tiếp tục ép mức sai số dự đoán xuống mức thấp nhất.
- **Bổ sung dữ liệu không gian và kinh tế vĩ mô:** Làm giàu dữ liệu (Data Enrichment) bằng cách thu thập thêm các thông tin về tọa độ địa lý (khoảng cách đến trung tâm, trường học, bệnh viện) hoặc các chỉ số kinh tế (lãi suất vay thế chấp, lạm phát tại thời điểm bán).

- **Phát triển ứng dụng Web (End-to-End):** Đóng gói mô hình đã huấn luyện (pickle/joblib) và tích hợp vào một hệ thống Web API (sử dụng FastAPI, Flask, hoặc Node.js/React) để cung cấp công cụ định giá nhà tự động, cho phép người dùng nhập thông số và nhận kết quả dự đoán theo thời gian thực.

# 7 REFERENCES

# References